

# Teoria para o cálculo da curva

Fernando Pujaico Rivera

November 23, 2018

## Abstract

## 1 Calculando o peço dos cúmulos

Dada uma imagem em branco e preto (**M**), como mostrado na Figura 1, com




Figure 1: Imagem em branco e preto (**M**), Imagem com cúmulos formados por grupos de pixels brancos (**GMAP**)

valores binários onde os pixels com cor branca tem valor 1 e com cor preta 0. Se desejamos obter uma imagem com cúmulos formados pelos grupos de pixels brancos (**GMAP**); onde cada pixel é mapeado com um índice  $ID$  ( na figura este  $ID$  está representado com uma cor); devemos seguir o procedimento das seguintes seções.

### 1.1 Modelando o problema

Nosso problema principal é obter, a partir de uma matriz **M**, uma matriz **GMAP** onde cada elemento contem o índice do cúmulo ao qual pertence, como mostra a Figura 1. Assim, pra cumprir este objetivo são usadas as funções *funA* e *funB*, como mostra a Figura 2, onde são analisadas de maneira sequencial as colunas  $\mathbf{M}(:, i)$  da matriz **M**, desde  $i = 0$  ate  $i = N_{col} - 1$ ,

A função *funA* recebe como parâmetro de entrada a coluna  $\mathbf{M}(:, 0)$  (primeira coluna da matriz **M**) e retorna o valor dos índices em **GMAP**(:, 0), adicionalmente a função retorna o valor do maior índice atribuído nas operações ( $MAX\_ID$ ).

Por outro lado a função *funB* recebe como parâmetros de entrada a  $i$ -essima coluna ( $\mathbf{M}(:, i)$ ) de **M**, o mapa de índices **GMAP**(:, 0 : ( $i - 1$ )) que abrange informações de índice desde a primeira coluna ate a ( $i - 1$ )-essima o valor do maior índice conhecido ate o momento, a função retorna o a matriz

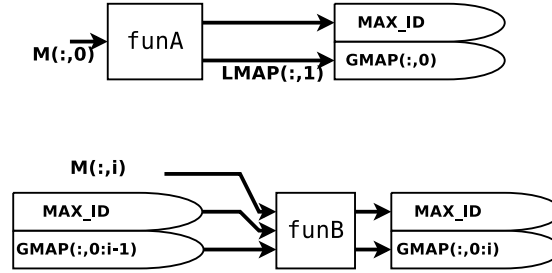


Figure 2: Diagrama de fluxo del algoritmo de criação de cúmulos

$\mathbf{GMAP}(:, 0 : i)$  com os dados dos índices desde a primeira coluna ate a  $i$ -essima, adicionalmente a função retorna o valor do maior índice atribuído nas operações ( $MAX\_ID$ ).

### 1.1.1 Algoritmo da função $funA$

A função  $funA$  recebe um vetor coluna  $\mathbf{V}$  com uns e zeros, como é exemplificado na Figura 3, na saída a função retorna um vetor  $\mathbf{LMAP}$  com o mesmo tamanho porem com elementos com valores inteiros, representado estes o mapeamento dos índices dos elementos em  $\mathbf{V}$ , os elementos em  $\mathbf{V}$  com valor zero recebem




Figure 3: Descrição da função  $funA$

automaticamente um índice de valor 0, já se uma região de uns em  $\mathbf{V}$ , estão isolados, estes recebem em  $\mathbf{LMAP}$  um índice com um valor maior em uma unidade do ultimo índice achado; a função  $funA$  também retorna o máximo índice estabelecido ( $MAX\_ID$ ).

### 1.1.2 Algoritmo da função $funB$

A função  $funB$  recebe como parâmetros de entrada, um vetor  $\mathbf{M}(:, i)$  correspondente a  $i$ -essima coluna da matriz  $\mathbf{M}$ , uma matriz  $\mathbf{GMAP}(:, 0 : (i - 1))$  com o mapa de grupos desde a primeira coluna ate a  $(i - 1)$ -essima coluna da matriz  $\mathbf{GMAP}$ , e o máximo índice  $MAX\_ID$  nos elementos da matriz  $\mathbf{GMAP}(:, 0 : (i - 1))$ , como é exemplificado na Figura 4. Na saída a função retorna uma matriz  $\mathbf{GMAP}(:, 0 : i)$  com o mapa de grupos desde a primeira coluna ate a  $i$ -essima coluna da matriz  $\mathbf{GMAP}$ , e o novo máximo índice  $MAX\_ID$  nos elementos da matriz  $\mathbf{GMAP}(:, 0 : i)$ . A função  $funB$  analisa os elementos do vetor  $\mathbf{M}(:, i)$ , desde a primeira linha ate a linha  $M\_NLIN$ , mediante as




Figure 4: Descrição da função *funB*

funções auxiliares *funB1*, *funB2* e *funB3*, estas funções modificam o conteúdo da matriz **GMAP**(:,0 : *i*) e a variável *MAX\_ID*.

**Algoritmo da função *funB1*:** A função recebe como parâmetros de entrada os vetores **M**(:, *i*), **GMAP**(:, *i*) e uma variável com a linha *lin* onde iniciará o análise. Se existem zeros em **M**(:, *i*), então se escrevem zeros nos elementos na mesma posição do vetor **GMAP**(:, *i*). Figura 5

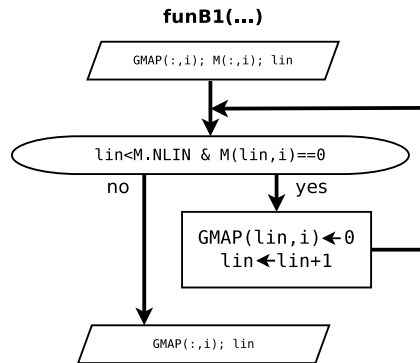


Figure 5: Descrição da função *funB1*

**Algoritmo da função *funB2*:** Verifico si existem uns; e acho o conjunto de ID globais ligados a esse grupo de uns, adicionalmente é contada a quantidade de uns. Figura 6

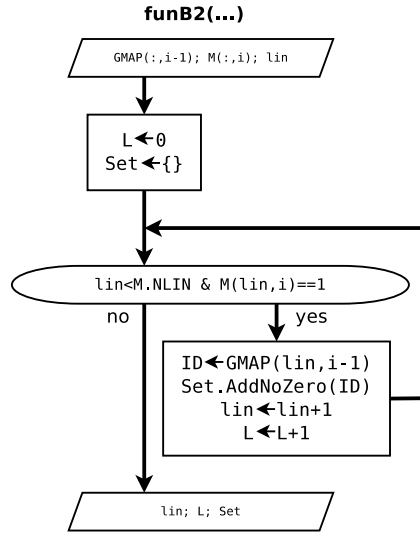


Figure 6: Descrição da função *funB*

## 1.2 Calculando a matriz GMAP e W

## 2 least-squares fitting of cubic splines (Method 1)

Este trabalho mostra como calcular o encaixe de uma curva  $y = f(x)$  mediante mínimos quadrados sobre um conjunto de  $N$  pontos  $(x_n, y_n)$ ;  $\forall n \in \mathbb{Z}$ ,  $0 \leq n < N$ ; tendo cada ponto uma importância de  $w_n$ . Onde a curva  $y = f(x)$  esta composta de um grupo de  $M$  splines cúbicos, como o exemplo da Figura 7.




Figure 7: Fitting of  $M = 6$  cubic splines in a set of  $N = 500$  pontos  $(x_n, y_n)$ .

Os splines tem seus limites de domínio, nas posições onde  $x$  tem valores  $\varepsilon_0, \varepsilon_1, \varepsilon_2, \dots, \varepsilon_M$ .

Assim, usando as variáveis  $\mathbf{E} = (\varepsilon_0 \ \varepsilon_1 \ \dots \ \varepsilon_M)^T$  e  $\mathbf{P} = (P_0 \ P_1 \ \dots \ P_{4M-1})^T$ ,

podemos definir as seguintes funções,

$$G(x, a, b) = \begin{cases} 1 & \text{if } a \leq x \leq b \\ 0 & \text{if } \text{other case} \end{cases} \quad (1)$$

$$S_k(x, \mathbf{P}) = P_{4k} x^3 + P_{1+4k} x^2 + P_{2+4k} x + P_{3+4k}, \quad (2)$$

de modo que

$$f(x, \mathbf{P}, \mathbf{E}) = \sum_{k=0}^{M-1} S_k(x, \mathbf{P}) G(x, \varepsilon_k, \varepsilon_{k+1}) \quad (3)$$

## 2.1 Modelando o problema

Para poder calcular o vetor  $\mathbf{P} = (P_0 \ P_1 \ P_2 \ \dots \ P_{4M-1})^T$ , do problema spline descrito na Seção 2, a partir dos dados  $(x_n, y_n, w_n); \forall n \in \mathbf{Z}, 0 \leq n < N$  e escolhidos os valores  $\mathbf{E} = (\varepsilon_0 \ \varepsilon_1 \ \dots \ \varepsilon_M)^T$ ; ordenamos nossos dados nos seguintes vetores coluna:

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_0 \\ \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_{M-1} \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} \mathbf{Y}_0 \\ \mathbf{Y}_1 \\ \vdots \\ \mathbf{Y}_{M-1} \end{pmatrix}, \quad \mathbf{W} = \begin{pmatrix} \mathbf{W}_0 \\ \mathbf{W}_1 \\ \vdots \\ \mathbf{W}_{M-1} \end{pmatrix}, \quad (4)$$

onde os elementos de  $\mathbf{X}_m, \mathbf{Y}_m, \mathbf{W}_m$  representam os valores de  $(x_n, y_n, w_n)$  que cumprem  $\varepsilon_m \leq x_n \leq \varepsilon_{m+1}$ .

### 2.1.1 Equação que relacionam os dados

Os dados  $(x_n, y_n)$  são agrupados em  $\mathbf{Y} = \mathbf{A}\mathbf{P}$ , onde,

$$\mathbf{A}_m = (\mathbf{X}_m^3 \ \mathbf{X}_m^2 \ \mathbf{X}_m \ \mathbf{1}) \quad (5)$$

$$\mathbf{A} = \begin{pmatrix} \mathbf{A}_0 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{A}_1 & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{A}_2 & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{A}_{M-1} \end{pmatrix} \quad (6)$$

### 2.1.2 Equação de continuidade dos splines consecutivos

Dados os polinômios  $S_{k-1}(x, \mathbf{P})$  e  $S_k(x, \mathbf{P})$  do  $(k-1)$ -ésimo e  $k$ -ésimo spline, respetivamente. Podemos igualar ambos polinômios para garantir a continuidade dos splines em  $x = \varepsilon_k$ , de modo que,

$$S_{k-1}(\varepsilon_k, \mathbf{P}) = S_k(\varepsilon_k, \mathbf{P}) \quad (7)$$

Assim, agrupando as equações dos polinômios de  $0 < k < M$ , obtemos  $\mathbf{0} = \mathbf{B}_0 \mathbf{P}$ , onde,

$$\mathbf{B}_0 = \begin{pmatrix} \mathbf{E}_1 & -\mathbf{E}_1 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{E}_2 & -\mathbf{E}_2 & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{E}_3 & -\mathbf{E}_3 & \dots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \vdots & \vdots & \dots & \vdots & \vdots \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{E}_{M-1} & -\mathbf{E}_{M-1} \end{pmatrix}, \quad (8)$$

usando como variável auxiliar,

$$\mathbf{E}_k = \begin{pmatrix} \varepsilon_k^3 & \varepsilon_k^2 & \varepsilon_k & 1 \end{pmatrix}. \quad (9)$$

### 2.1.3 Equação de continuidade da 1ra derivada dos splines consecutivos

Dados os polinômios  $S_{k-1}(x, \mathbf{P})$  e  $S_k(x, \mathbf{P})$  do  $(k-1)$ -ésimo e  $k$ -ésimo spline, respetivamente. Podemos igualar a primeira derivada de ambos polinômios para garantir a continuidade dos splines em  $x = \varepsilon_k$ , de modo que,

$$\left. \frac{\partial S_{k-1}(x, \mathbf{P})}{\partial x} \right|_{x=\varepsilon_k} = \left. \frac{\partial S_k(x, \mathbf{P})}{\partial x} \right|_{x=\varepsilon_k} \quad (10)$$

Assim, agrupando as equações dos polinômios de  $0 < k < M$ , obtemos  $\mathbf{0} = \mathbf{B}_1 \mathbf{P}$ , onde,

$$\mathbf{B}_1 = \begin{pmatrix} \partial \mathbf{E}_1 & -\partial \mathbf{E}_1 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \partial \mathbf{E}_2 & -\partial \mathbf{E}_2 & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \partial \mathbf{E}_3 & -\partial \mathbf{E}_3 & \dots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \vdots & \vdots & \dots & \vdots & \vdots \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \partial \mathbf{E}_{M-1} & -\partial \mathbf{E}_{M-1} \end{pmatrix}, \quad (11)$$

usando como variável auxiliar,

$$\partial \mathbf{E}_k = \begin{pmatrix} 3\varepsilon_k^2 & 2\varepsilon_k & 1 & 0 \end{pmatrix}. \quad (12)$$

### 2.1.4 Equação de continuidade da 2da derivada dos splines consecutivos

Dados os polinômios  $S_{k-1}(x, \mathbf{P})$  e  $S_k(x, \mathbf{P})$  do  $(k-1)$ -ésimo e  $k$ -ésimo spline, respetivamente. Podemos igualar a segunda derivada de ambos polinômios para garantir a continuidade dos splines em  $x = \varepsilon_k$ , de modo que,

$$\left. \frac{\partial^2 S_{k-1}(x, \mathbf{P})}{\partial x^2} \right|_{x=\varepsilon_k} = \left. \frac{\partial^2 S_k(x, \mathbf{P})}{\partial x^2} \right|_{x=\varepsilon_k} \quad (13)$$

Assim, agrupando as equações dos polinômios de  $0 < k < M$ , obtemos  $\mathbf{0} = \mathbf{B}_2 \mathbf{P}$ , onde,

$$\mathbf{B}_2 = \begin{pmatrix} \partial^2 \mathbf{E}_1 & -\partial^2 \mathbf{E}_1 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \partial^2 \mathbf{E}_2 & -\partial^2 \mathbf{E}_2 & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \partial^2 \mathbf{E}_3 & -\partial^2 \mathbf{E}_3 & \dots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \vdots & \vdots & \dots & \vdots & \vdots \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \partial^2 \mathbf{E}_{M-1} & -\partial^2 \mathbf{E}_{M-1} \end{pmatrix}, \quad (14)$$

usando como variável auxiliar,

$$\partial^2 \mathbf{E}_k = \begin{pmatrix} 6\varepsilon_k & 2 & 0 & 0 \end{pmatrix}. \quad (15)$$

## 2.2 Calculando os parâmetros $P_j$

Agrupando os resultados da Seção 2.1, podemos definir a seguinte equação,

$$\begin{pmatrix} \mathbf{Y} \\ \mathbf{0} \\ \mathbf{0} \\ \mathbf{0} \end{pmatrix} = \begin{pmatrix} \mathbf{A} \\ \mathbf{B}_0 \\ \mathbf{B}_1 \\ \mathbf{B}_2 \end{pmatrix} \mathbf{P} \quad (16)$$

ou seu equivalente,  $\mathbf{Z} = \mathbf{QP}$ . Onde a única incógnita é  $\mathbf{P}$ .

Para resolver este problema aplicamos *LMS* (Least Mean Square) a equação, para isso definimos a regra de minimização  $e(\mathbf{P})$ ,

$$e(\mathbf{P}) = \|\mathbf{Z} - \mathbf{QP}\|_{diag(\mathbf{W})}^2 + \alpha \|\mathbf{P} - \mathbf{P}_*\|. \quad (17)$$

Onde  $\mathbf{P}_*$  é o valor de  $\mathbf{P}$  na iteração anterior. Assim, aplicando *LMS* e a regularização de Tikhonov, o mínimo valor de  $\mathbf{P}$  se obtém iterativamente usando a seguinte equação

$$\mathbf{P}_{k+1} = \mathbf{P}_k + [\mathbf{Q}^T diag(\mathbf{W}) \mathbf{Q} + \alpha \mathbf{I}]^{-1} \mathbf{Q}^T diag(\mathbf{W}) [\mathbf{Z} - \mathbf{QP}_k] \quad (18)$$

ate que os vetores  $\mathbf{P}_k$  e  $\mathbf{P}_{k+1}$  sejam muito próximos.